

Kokkuvõte artiklist:

A Conceptual Introduction to Hamiltonian Monte Carlo

Hamiltoni Monte Carlo meetodi kontseptuaalne tutvustus

Rakendusstatistikas on laialdaselt kasutusel Markovi ahela Monte Carlo (MCMC) meetodid, mida kasutatakse keerulisemate mitmedimensionaalsete tõenäosusjaotuste järgi valimite genereerimiseks ja nendele vastavate juhusliku suuruste keskvärtuse, dispersiooni ja kõrgemat järku momentide numbriliseks arvutamiseks. Üks levinumaid seda tüüpi meetodeid on esimene MCMC algoritm Metropolis-Hastings (MHMC), mille leiutasid Los Alamosi labori teadlased osalenud teadlased 1950-ndatel aastatel statistilise mehaanika uurimistöö käigus. Hamiltoni Monte Carlo (HMC) on 1980-ndatel leiutatud analüütilise mehaanika ideedega täiustatud MHMC edasiarendus, mida rakendati kõige esimesena võrepõhises kvantkromodünaamikas kvarkide dünaamika arvutustes. Tänapäeval kasutatakse HMC-d astronoomias, meditsiiniteaduses ja finantsturgude analüüsis. Antud artikkel annab intuiitiivse ja põhjaliku ülevaate HMC algoritmi olemuse kohta, võrdleb HMC eeliseid MHMC ees ning tutvustab ka selle meetodi kitsaskohti. Olgugi et HMC-d leiutati juba 1980-ndatel, on alles hiljuti HMC algoritmi olemust hakatud rangelt matemaatiliselt põhjendada.

Olgu mingis n -dimensioonilises valimiruumis Q defineeritud tõenäosustihedusfunktsioon ja mingi uuritav funktsioon vastavalt $\pi(q), f(q)$, $q \in Q$. Antud valimiruumis avaldub uuritava funktsiooni keskvärtus analüütilise eeskirja järgi integraalina

$$E_{\pi}[f] = \int_Q f(q)\pi(q)dq.$$

Tihedusfunktsiooni maksimumile vastav argument $q_{\text{mode}} = \operatorname{argmax}_q \pi(q)$ on ühtlasi selle jaotuse lokaalne mood. Võiks ju arvata, et kuna tihtipeale keskvärtuse naabruskond langeb lähestikku moodiga, nagu teadatud üldise Gaussi jaotuse või Boltzmanni jaotuse puhul peab paika, siis võiks jaotuse numbriline integreerimine toimuda moodi vahetus läheduses. Üldise konstruktsiooni põhjal nähtub siiski, et valimiruumi dimensiooni kasvades annab järjest suurema panuse keskvärtuse arvutamisse integrandi osa $\pi(q)dq$ ehk tõenäosusmass, mille üle infinitesimaalse kesta integreeritud maksimumi ruumipiirkond ruumi dimensiooni kasvades järjest vähem langeb kokku jaotuse moodiga. Näiteks 3D ristkoordinaadistikus võib jaotuse moodi asukohale vastavale diskretiseeritud infinitesimaalsele ühikrakule $dx dy dz$ vastata naabruse suurim tihedusfunktsiooni väärtus, kuid kuna tema vahetute infinitesimaalsete naabrite arv on 3D-s juba 26 ja nD -s $3^n - 1$, siis moodi täpse asukoha panus keskvärtuse arvutamisse dimensiooni kasvades hääbub. Artikli autor nimetab seda ruumi osa, kus $\pi(q)dq$ panus on suurim, jaotuse tüüphulgaks. Selleks, et numbriliselt arvutada kõrgemadimensiooniliste jaotuste integraale või genereerida neid jaotusi järgivaid juhuvalimeid, pole mõistlik naiivsetele numbrilistele meetoditele omaselt itereerida üle diskretiseeritud valimiruumi sõlmpunktide ning igale diskreetsele sõlmpunktile paiknevale tüüprakule määrata tihedusfunktsiooni väärtus või keskvärtuse integrandi suurus. Optimaalsem oleks konstrueerida teatud tüüpi realisatsioonide ahel, mis järgib tüüphulga geomeetriat ehk mitmedimensioonilist kesta, kus $\pi(q)dq$ panus jaotuse keskvärtusesse on suurim.

Üldise kontseptuaalse MCMC eesmärk on genereerida diskreetne hulk juhuvalimeid $\{q_0, q_1, \dots, q_N\}$, selliselt, et juhuvalimi väärtuste esinemissagedus jäljendaks uuritavat jaotust ehk nende põhjal konstrueeritav histogramm matkiks tihedusfunktsiooni $\pi(q)$. Jahuvalimite hulk $\{q_0, q_1, \dots, q_N\}$ konstrueeritakse Markovi ahelana, ehk vastavalt Markovi omadusele kehtib $q_{n+1} \sim P\{q_{n+1}|q_n\}$ ehk igale järgnevale juhuvalimi liikmele omistatakse väärtus tingliku tõenäosuse järgi sõltuvalt eelmisest realisatsioonist. Lihtsaim algoritm, juhusliku ekslemisega MHMC, lisab eelnevale realisatsioonile Gaussi ühikjaotuse järgi skaleeritud nihke ning kontrollib, kas uuele kandidaatrealisatsioonile q' vastab eelnevast realisatsioonist suurem väärtus või väiksem tõenäosustiheduse väärtus. Kui vastab suurem, siis saab

järgmine ahela liige kindlasti selle uue väärtuse. Kui on väiksem, siis uuele ahela liikmele omistatakse uus arvutatud väärtus või vana, sõltuvalt sellest, kas $\pi(q')/\pi(q_n) \geq \alpha$, kus $\alpha \sim \text{Unif}(0,1)$. Suurim probleem MHMC algoritmide puhul on asjaolu, et nende genereeritud ahelad kipuvad koonduma jaotuse moodi vahetus ümbruses ja mitte tüüphulgal. Ahela moodustamist tüüphulgal saab käsitleda otsekui tiirlemist orbiidil, seetõttu täiendab HMC neid algoritme valimiruumi vabadusastmetele vastavate üldistatud impulsside $p \in R^n$ sissetoomisega selleks, et tihedusfunktsiooni määratud potentsiaalväljas jäljendada tüüphulgal püsimiseks tarvilikku dünaamikat.

HMC käsitleb tõenäosustihedusfunktsiooni $\pi(q)$ kui mingisuguse konservatiivse dünaamilise süsteemi määratud tõenäosustihedust kujul $\pi(q) \sim e^{-U(q)}$ ehk vastav jaotus saab „potentsiaalne energia“ ja „kineetilise energia“

$$U(q) = -\log \pi(q), \quad K(p) = \frac{1}{2} p^T M^{-1} p + \text{const}, \quad H(q, p) = K(p) + U(q)$$

kus M on massimaatriks. HMC-ga genereeritakse $K + 1$ -liikmeline juhuvalim $\{q_0, q_1, \dots, q_K\}$ selliselt, et iga järgmise realisatsiooni jaoks initsialiseeritakse esmalt suvaline üldistatud impulss p_0 Gaussi jaotuse järgi $p_0 \sim \mathcal{N}(0, M^{-1})$. Sellele järgneb Hamiltoni dünaamika ehk diferentsiaalvõrrandisüsteemi

$$\dot{p} = -\nabla_q H(q, p) = \nabla U(q), \quad \dot{q} = \nabla_p H(q, p) = M^{-1} p$$

diskreetsel kujul lahendamine L diskreetse sammu jaoks numbriliselt integreerides. Numbriline integreerimine teostatakse sümplektilise ehk energia jäävust tagava sikhüppe (*leapfrog*) integreerimisalgoritmi abil, mille skeem on alljärgnev:

$$p_{i+\frac{1}{2}} = p_i + \frac{\Delta t}{2} \nabla U(q_i), \quad q_{i+1} = q_i + M^{-1} p_{i+\frac{1}{2}}, \quad p_{i+1} = p_{i+\frac{1}{2}} + \frac{\Delta t}{2} \nabla U(q_{i+1}).$$

Leapfrog-i ainus sisuline erinevus Euleri meetodist on see, et iga uue diskreetse positsiooni kohta arvutatakse kaks uut diskreetset impulsi väärtust lõigu keskel ja lõpus. See on piisav, et erinevalt Euleri või Runge-Kutta meetoditest tagada süsteemi energiajäävus peale pikki arvutusi. Nüüd see, kas uuele ahelaliikmele omistatakse uus väärtus $p_{n+1} = p_L$ sõltub alljärgneva kriteeriumitõenäosusese võrratuse kehtimisest (kummutamisel $p_{n+1} = p_n$)

$$\alpha \leq \min\{1, \exp(-H(q_L, -p_L) + H(q_n, p_0))\}, \quad \alpha \sim \text{Unif}(0,1).$$

Idealis on moodid vaadeldavad kui välja allikad ning tüüphulgad on stabiilsed orbiidid nende ümber või võnkumised läbi nende. Liiga suurte initsialiseeritud impulsside panused kajastuvad harvemini, kuna viivad jõuväljast lahkuvate trajektoorideni. HMC rakendamisel tuleb arvestada, et kui Hamiltoni dünaamikat tihedusfunktsiooni peal simuleerida, peab tihedusfunktsiooni logaritm olema tüüphulga naabruses pidevalt diferentseeruv ehk see peab olema seal sile ja ilma singulaarsusteta. Lisaks veel on üks suurimaid puudujääke olukord, mil tihedusfunktsioonist tekkiv jõuväli käitub kui harmooniline ostsillaator ning suurem osa L integreerimissammust teevad üleliigset tööd. Selleks rakendatakse algoritmi *No U-Turn Sampler*, mis kahendpuu andmestruktuuri abil kontrollides peatab tagasipöördumise korral sikhüppe integreerimised. Suurim väljakutse efektiivse HMC arendamisse on efektiivne parameetrite valik. Kõige kriitilisemad on numbrilisel integreerimisel rakendatav ajasamm ja massimaatriks. Eukleidilises valimiruumis avaldub konstruktsiooni põhjal optimaalseim massimaatriks kui diagonaalmaatriks, mille peadiagonaali iga liige on vastava vabadusastme dispersioon, seega nn. HMC soojendusfaasis arvutatakse marginaaldispersioonid tihedusfunktsiooni sisenditele, et neist koostada uuendatud massimaatriks.

HMC puhul tegu olulise statistilise vahendiga, mida järjepidevalt uuritakse ja arendatakse. See on analüütilise mehaanika ideedel põhinev algoritm, mis leiab rakendust füüsikast kaugematel aladel nagu majandus ja farmakomeetria, kinnitades matemaatilise füüsika ja analüütilise mehaanika ideede universaalsust.